Introduction à OpenMP

1 Création d'une équipe de threads

La directive #pragma omp parallel indique que l'instruction ou le bloc d'instructions suivant cette directive doit être réalisé par une *équipe* de threads. On appelle *section parallèle* l'instruction ou le bloc concerné par la directive.

```
#include <stdio.h>

int main()

{

printf("Bonjour_!\n");

printf("Au_revoir_!\n");

return 0;

}
```

- 1. Modifiez le programme hello.c en ajoutant une directive parallel en ligne 5.
- 2. Compilez puis exécutez le programme comme-ci de rien n'était : gcc hello.c ; ./a.out.
- 3. Recompilez en donnant cette fois l'option -fopenmp à gcc. Exécutez le programme plusieurs fois. Combien de threads sont utilisés? Comparez ce nombre au nombre de coeurs (logiques) de votre machine. À quel moment s'affiche le message «Au revoir!»?
- 4. La variable d'environnement OMP_NUM_THREADS permet de contrôler le nombre de threads utilisés par défaut. Lancez l'exécution en entrant la commande OMP_NUM_THREADS=13 ./a.out .
- 5. La fonction omp_get_thread_num() retourne le numéro d'équipier (l'identité) du thread qui l'appelle. Sa mise en œuvre nécessite l'inclusion du fichier <omp.h>. Modifiez les deux appels à printf() de sorte à afficher également le numéro du thread appelant. Compilez puis exécutez plusieurs fois le programme en faisant varier le nombre de threads. L'ordre d'exécution est-il toujours le même?
- 6. Faites en sorte que chaque thread affiche également le message « Au revoir » en englobant dans une seule section parallèle les deux appels à printf. Testez le programme avec une bonne douzaine de threads.
- 7. La directive #pragma omp barrier permet à une équipe de threads de se fixer un rendez-vous (de s'attendre) à une ligne de code donnée. Insérer une directive barrier entre les deux appels à printf. Compilez et testez le programme.

2 Section critique

La directive #pragma omp critical impose que chaque thread exécute l'instruction ou le bloc d'instructions suivant en solitaire. Le code gardé par la directive critical est appelé section critique et on dit que la section critique est exécutée en exclusion mutuelle. Utiliser la directive critical pour faire en sorte que les affichages des différents threads ne s'entremêlent pas (NB. on supprimera la barrière placée lors de l'exercice précédent).

3 Variable partagée vs variable privée

Dans le programme partage.c on déclare k et i deux variables locales à la fonction main.

```
1 #include <stdlib.h>
  #include <stdio.h>
3 #include <omp.h>
5 int
6 main()
7 {
    int k = 0;
10
11 #pragma omp parallel
12
    int i;
13
    for (i = 0; i < 100000; i++)
14
15
      k++;
16
17
  printf("nbthreads_x_100000_=_%d\n_",k);
18
  return 0;
19
```

La variable k est déclarée avant l'appel à la directive parallel, cette variable sera partagée entre les différents threads : tout thread de la section parallèle suivante pourra consulter / modifier à loisir cette variable.

La variable i est déclarée à l'intérieur de la section parallèle, c'est une variable privée du thread : chaque thread aura son propre exemplaire et ne pourra pas modifier l'exemplaire d'un autre thread.

- 1. Compilez puis exécutez le programme partage.c. On observe que la valeur affichée est exceptionnellement un multiple de 100000 et que, finalement, cette valeur change d'une exécution à l'autre. Manipuler sans précaution une variable partagée conduit à un résultat indéterminé.
- 2. Insérez une section critique en ligne 15, compilez, testez. Le programme ne vous semble-t-il pas lent?

4 Distribution d'une boucle for

On cherche à calculer en parallèle la somme des éléments d'un vecteur dans le but de gagner du temps. Voici le code :

```
1 int sum = 0;
2
3 for(int i = 0; i < N; i++)
4    sum+=t[i];</pre>
```

Notre objectif est de calculer autant de fois plus vite qu'il y a de cœurs sur la machine. Pour cela il s'agit de distribuer (équitablement) les indices de la boucle for aux différents threads en faisant en sorte que chaque indice soit traité exactement une fois. À la lumière des exercices précédents (et sans écrire de programme) detérminer quels sont les défauts/avantages les trois codes suivants :

```
1. Version 1
     1 int sum = 0;
     3 #pragma omp parallel
         for (int i = 0; i < N; i++)</pre>
          sum+=t[i];
    2. Version 2
     1 int sum = 0;
     _{2} int i = 0;
     4 #pragma omp parallel
     5 {
        int mon_i;
       int ma_somme = 0;
       for(;;)
     10
            #pragma omp critical
           mon_i = i++;
     11
     12
            if (mon_i > N)
               break;
     14
     15
           ma_somme += t[i];
     16
            #pragma omp critical
     18
            sum += ma_somme ;
     19
     20 }
    3. Version 3 où on utilise le nombre de threads engagés via un appel à omp_get_num_thread()
     1 int sum = 0;
     3 #pragma omp parallel
     int mon_i;
int ma_somme = 0;
     7 int nb_threads = omp_get_num_thread();
         for(mon_i = omp_get_thread_num(); mon_i < N ; mon_i += nb_threads)</pre>
     10
           ma_somme += t[mon_i];
     11
            #pragma omp critical
            sum += ma_somme ;
     13
     14 }
    La directive #pragma omp for permet de coder efficacement la version 3 :
1 int sum = 0;
3 #pragma omp parallel
5 int i;
6 int ma_somme = 0;
8 #pragma omp for schedule(static,1)
   for (i=0; i < N; i++)</pre>
      ma_somme += t[i];
      #pragma omp critical
      sum += ma_somme ;
```

11

12

13 14 } La directive omp for indique que les indices de la boucle qui suit sont à répartir entre les threads et la clause schedule précise l'algorithme de distribution à utiliser. Il y a quatre principaux types de distribution :

- schedule(static) indique que les indices sont à distribués équitablement en autant de blocs d'indices consécutifs qu'il y a de threads;
- schedule (static, k) indique que les indices doivent être distribués cycliquement par blocs de k indices.
- schedule (dynamic, k) indique que les indices doivent être distribués à la demande par blocs de k indices. Notons que la version 2 du code peut être obtenue en utilisant la clause schedule (dynamic, 1).
- schedule (guided, k) pour les curieux.

Notons enfin que la directive pragma omp parallel for est la contraction de l'enchaînement des directives parallel puis for.

Étudions ces différentes politiques à l'aide du programme boucle-for.c:

```
1 #include <stdlib.h>
2 #include <stdio.h>
4 #include <omp.h>
6 int
7 main()
8 {
    int i;
10
    for (i=0; i < 40; i++)
11
      printf("%d_traite_%i\n",omp_get_thread_num(),i);
12
13
    return 0:
14
15 }
```

- 1. Tout d'abord placez une directive parallel for en ligne 10. Compilez et testez plusieurs fois.
- 2. Modifiez le programme pour tester différentes politiques de distribution. Utilisez la commande ./a.out | sort -n -k 3 pour visualiser plus facilement le travail réalisé.

5 Calcul de la somme d'un tableau - réduction

Nous avons vu qu'il était nécessaire de protéger les accès aux variables partagées. Ceci peut se faire à l'aide de sections critiques mais aussi à l'aide d'instructions atomiques. Une section atomique est une section critique réduite à une instruction. Nous allons comparer le coût de différentes technique de protection sur le code suivant :

```
for (i=0; i<taille;i++)
  sum += tab[i];</pre>
```

Remplacez les TODO du programme sum.c par les techniques suivantes :

- 1. section parallel for où la variable sum partagée est accédée en section critique,
- 2. section parallel for où la variable sum partagée est accédée en section atomique #pragma omp atomic,
- 3. réduction #pragma omp parallel for reduction (+: sum) : le compilateur transforme le programme pour introduire une variable locale afin de minimiser le temps passé en section critique.

6 Examen 2017 : Calculs de moyennes en OpenMP

Disposant d'une machine de 100 cœurs, on cherche à optimiser le temps d'exécution d'un programme calculant les moyennes de séquences de nombres flottants. Les nombres sont stockés dans un tableau elements et les séquences sont données par un tableau de structures, structures dont les champs debut et fin désignent des indices du tableau elements. On pourra supposer les séquences disjointes. Voici les structures de données :

```
struct { int debut; int fin; } sequences[N];
double elements[M];
double moyennes[N];

Pour fixer les idées, voici un exemple de valeurs cohérentes:
  sequences[] = {{0,3}, {5,6}}
  elements[] = {0.0, 1.0, 2.0, 3.0, 4.0, 5.0, 10.0, 9.0}
  moyennes[] = {1.5, 7.5}
```

Question 1 Proposez un code OpenMP optimisé du calcul des moyennes des séquences pour le cas où le nombre de séquences est bien supérieur au nombre de threads (e.g. N = 10 000 000)). On pourra supposer toutes les séquences sont à peu près de la même longueur et assez petites (eg. de longueur 4).

Question 2 Proposez un code OpenMP optimisé pour le cas où le nombre de séquences est bien plus petit que le nombre de threads (e.g. 4 séquences de longueur 10 000 000).

Question 3 On appelle efficacité parallèle d'un programme le rapport :

```
\frac{\text{Temps exécution séquentielle}}{\text{Temps exécution parallèle} \times \text{nombre de cœurs}}
```

En supposant disposer de 100 cœurs, estimer l'efficacité parallèle obtenue (dans le pire cas) par chaque code dans les configurations suivantes :

- 1. 10 000 000 séquences de longueur 4;
- 2. 4 séquences de longueur 10 000 000;
- 3. 4 séquences de longueur 10 000 000 perdues au milieu de 10 000 000 de séquences de longueur 4.

Question 4 On cherche à obtenir un programme parallèle efficace dans les trois cas précédents. On propose d'enchainer des versions modifiées du premier code puis du second code tout en évitant de parcourir plus d'une fois le tableau des séquences. Pour cela on définit une constante SEUIL et un tableau int gros_cas[N] qui va servir à mémoriser les indices des séquences de longueur supérieure à SEUIL.

Proposez un code OpenMP basé sur une version modifiée du premier code afin de traiter les petites séquences et mémoriser les indices des longues séquences dans le tableau gros_cas[] pour enchainer sur le second code qui ne traitera que les longues séquences, celles mémorisées dans gros_cas[].